2025학년도 학사학위논문 (종합설계보고서)
지도교수 전 웅 선

MPC 기반 모방학습을 이용한 자율주행 차선변경 시스템

중앙대학교 전자전기공학부
이 원 회 (20226115)
2025. 12. 04

목차

I. 서론 3
1. 연구 배경 및 필요 3
2. 연구 목적 및 범위 3
II. 관련 연구 4
1. 자율주행 차선변경 시스템 4
2. 모델 예측 제어 5
3. 모방학습 기반 제어 5
III. 시스템 설계 6
1. 전체 시스템 구조 6
2. 시뮬레이션 환경 6
3. 소프트웨어 구조 7
IV. 의사결정 및 경로 계획 8
1. 유한상태기계 기반 의사결정 8
2. MPC 기반 횡방향 경로 계획 9
3. 규칙 기반 종방향 속도 제어 10
4. 통합 제어 구조 10
V. 모방학습 기반 정책 학습 11
1. 학습 데이터 생성 11
2. 신경망 구조 설계 11
3. 학습 알고리즘 12
VI. 실험 및 결과 분석 13
1. 실험 환경 및 시나리오 13
2. Teacher 정책 성능 13
3. 학습 데이터 분석 15
4. Student 정책 학습 및 분석 17
5. 논의 20
VII. 결론 20
참고문헌 21

I. 서론

1. 연구 배경 및 필요성

자율주행 기술은 교통사고 감소, 운전자 편의성 향상, 교통 효율 증대 등의 사회적 효과로 인해 전 세계적으로 활발히 연구되고 있다. 자율주행 시스템의 핵심 기능 중 하나인 차선변경은 장애물 회피, 추월, 경로 계획 등 다양한 상황에서 필수적으로 요구되며, 주변 환경 인식, 실시간 의사결정, 정밀한 경로 추종 등 복잡한 문제를 포함한다. 특히 동적이고 예측 불가능한 도로 환경에서 안전하고 효율적인 차선변경을 수행하기 위해서는 다양하고 정확한 센서로부터 받은 정보를 바탕으로 적절한 시점에 차선변경을 결정하고, 목표 경로를 정확하게 추종하기 위한 제어 명령을 생성해야 한다.

차선변경을 위한 자율주행 시스템은 크게 인지(perception), 의사결정(decision-making), 제어(control)의 세 단계로 구성된다. 인지 단계에서는 카메라, 라이다, 레이더 등의 센서를 통해 주변 차량, 장애물, 차선 정보를 획득한다. 의사결정 단계에서는 획득한 환경 정보를 바탕으로 차선변경 시점, 목표 경로, 주행 속도 등을 결정한다. 제어 단계에서는 결정된 목표를 정확하게 추종하기 위한 조향각과 속도 명령을 생성하여 차량을 구동한다. 이러한 각 단계는 실시간으로 동작해야 하며, 특히 제어 단계는 수십 Hz의 높은 주파수로 업데이트되어야 안정적인 주행이 가능하다.

모델 예측 제어(Model Predictive Control, MPC)는 차량 동역학 모델을 활용하여 미래 상태를 예측하고 최적 제어 입력을 계산하는 기법으로, 제약조건을 명시적으로 고려할 수 있어 자율주행 분야에서 널리 사용되고 있다[1][2]. MPC는 예측 구간(prediction horizon) 동안의 시스템 동작을 예측하고, 비용함수를 최소화하는 제어 입력 시퀀스를 계산한다. 이 과정에서 조향각, 속도, 가속도 등의 물리적 제약과 안전 거리, 차선 범위 등의 안전 제약을 동시에 만족시킬 수 있다. 그러나 MPC는 매 제어 주기마다 최적화 문제를 풀어야 하므로 계산 부담이 크며, 특히 예측 구간이 길거나 상태 변수가 많을 경우 실시간 성능을 보장하기 어렵다.

이러한 계산 복잡도의 한계를 극복하기 위해 모방학습(imitation learning)을 활용한 접근법이 주목받고 있다. 모방학습은 전문가 정책(expert policy)의 행동 데이터를 학습하여 신경망 기반의 경량 정책을 생성하는 방법으로, MPC와 같은 최적 제어 기법으로 생성된 데이터를 활용하면 계산 효율성과 제어 성능을 동시에 확보할 수 있다. 특히 Behavioral Cloning 기법은 지도학습 방식으로 Teacher의 상태-행동을 직접 학습하여 정책을 생성하며, 구현이 비교적 간단하고 오프라인 데이터만으로 학습이 가능하다는 장점이 있다. 학습된 신경망 정책은 forward propagation 연산만으로 제어 명령을 생성하므로, MPC의 반복적 최적화에 비해 계산 시간이 크게 단축되며, 계산 시간의 변동성도 낮아 실시간 시스템 배포에 유리하다.

그러나 모방학습의 성능은 학습 데이터의 품질에 크게 의존한다. 전문가 정책이 안전하지 않거나 최적이 아닌 행동을 생성하면, 학습된 정책도 그러한 결함을 그대로 재현하게 된다. 따라서 고품질의 expert 데이터를 생성하는 것이 모방학습 기반 자율주행 시스템의 핵심 과제이다. 특히 차량 제어에서는 조향각과 속도에 대한 물리적 제약이 존재하며, 이를 위반하는 데이터는 학습된 정책이 실제 배포 시 실행 불가능한 명령으로 만들 수 있다. MPC는 최적화 과정에서 제약조건을 고려하므로, 대부분의 제어 명령이 실행 가능함이 수학적으로 보장된다. 이는 전통적인 제어 기법이 제공하지 못하는 핵심 장점이다.

2. 연구 목적 및 범위

본 연구의 목적은 장애물 회피를 위한 자율 차선변경 시스템을 설계 및 구현하고, MPC 기반 전문가 정책(Teacher)과 모방학습 기반 신경망 정책(Student)의 성능을 비교 분석하는 것이다. 특히 MPC가 생성하는 데이터의 품질을 정량적으로 평가하고, 이를 기반으로 학습된 신경망이 실시간 제어에 적합한 성능을 제공하는지 검증한다.

본 연구의 구체적인 범위는 다음과 같다. 첫째, 의사결정 시스템으로 유한상태기계(Finite State Machine, FSM)를 설계한다. FSM은 차선 유지(KEEP_L2), 회피 기동(EVADE_L), 회피 차선 유

지(KEEP_L1), 복귀 기동(RETURN_TO_L2), 안전 정지(SAFE_STOP)의 5개 상태로 구성되며, 센서 정보를 기반으로 상태 전이를 결정한다. 각 상태는 명확한 전이 조건과 안전 메커니즘을 포함하여 시스템의 안정성을 보장한다.

둘째, MPC 기반 경로 계획 시스템을 구현한다. 차량의 kinematic bicycle model을 활용하여 횡방향 경로를 계획하며, 횡방향 오차(y)와 헤딩각(ψ)을 상태 변수로 사용하는 2-state MPC를 구현한다. 비용함수는 목표 차선으로의 수렴, 헤딩각 최소화, 조향각 크기 및 변화 최소화를 고려하도록 설계되며, 조향각 및 횡방향 위치에 대한 명시적 제약조건을 포함한다. OSQP(Operator Splitting Quadratic Program) solver를 사용하여 Quadratic Programming 문제를 실시간으로 해결한다.

셋째, 규칙 기반 종방향 제어 시스템을 구현한다. 전방 장애물과의 거리(front_gap)를 기반으로 안전한 주행 속도를 결정하며, 임계 거리 이하에서는 회피 기동을 시작하도록 한다. 횡방향 제어와 종방향 제어를 분리하는 구조를 통해 MPC의 계산 복잡도를 낮추고 실시간 성능을 확보한다.

넷째, 모방학습 기반 정책을 개발한다. 시뮬레이션 환경에서 MPC 정책으로부터 대규모 행동 데이터를 수집하고, 다층 퍼셉트론(Multi-Layer Perceptron, MLP) 기반 신경망을 학습하여 실시간 추론이 가능한 경량 정책을 생성한다. 신경망의 입력은 차량 상태, 센서 정보, FSM 상태를 포함하며, 출력은 조향각과 목표 속도이다. Behavioral Cloning 기법을 사용하여 MPC의 상태-행동을 직접 학습한다.

다섯째, 시뮬레이션 기반 검증을 수행한다. 다양한 장애물 시나리오에 대해 Teacher와 Student 정책의 제어 성능, 계산 시간, 안정성 등을 정량적으로 비교한다. 특히 MPC의 제약 만족률, 데이터 품질, 제어 부드러움 등을 상세히 분석하여 고품질 학습 데이터의 특성을 규명한다. Student 정책에 대해서는 학습 데이터 기반 분석을 통해 예상 성능을 추정한다.

본 연구는 시뮬레이션 환경으로 제한되며, 실제 차량에서의 검증은 향후 연구 과제로 남겨둔다. 또한 단일 정지 장애물 시나리오를 다루며, 다중 장애물이나 이동 장애물은 고려하지 않는다. 센서는 이상적인 것으로 가정하며, 센서 노이즈나 오차의 영향은 제한적으로만 반영한다.

II. 관련 연구

1. 자율주행 차선변경 시스템

자율주행 차선변경은 주변 환경 인식, 경로 계획, 차량 제어가 통합적으로 요구되는 복잡한 과제이다. Schwarting 등[1]은 자율주행 시스템의 계획 및 의사결정 기법을 포괄적으로 분석하였으며, 차선변경에서 안전성과 효율성을 동시에 고려해야 함을 강조하였다. 특히 차선변경 결정은 단순히 목적지로의 최단 경로만이 아니라, 주변 차량의 거동, 교통 흐름, 법규 준수 등 다양한 요소를 종합적으로 고려해야 한다.

차선변경 의사결정 방법은 크게 규칙 기반(rule-based) 접근법과 학습 기반(learning-based) 접근법으로 구분된다. 규칙 기반 방법은 명시적인 조건문과 안전 거리 기준을 활용하여 차선변경 가능 여부를 판단한다. 예를 들어, 목표 차선에 일정 거리 이상의 여유 공간이 있고, 후방 차량과의 상대 속도가 안전 기준을 만족하면 차선변경을 허용하는 방식이다. 이러한 접근법은 해석 가능성과 안전성 검증이 용이하다는 장점이 있다. 설계자가 각 조건의 의미를 명확히 이해할 수 있으며, 안전성 분석도 비교적 직관적이다. 그러나 복잡한 교통 상황에서는 규칙의 수가 폭발적으로 증가하며, 모든 상황을 사전에 고려하여 규칙을 설계하는 것이 사실상 불가능하다.

유한상태기계(FSM)는 차선변경과 같은 순차적 행동을 모델링하는 데 효과적인 방법이다. FSM은 시스템이 취할 수 있는 상태들과 각 상태 간의 전이 조건을 명확히 정의함으로써 복잡한 동작을 구조화할 수 있다. 차선변경 시나리오에서는 정상 주행, 차선변경 준비, 차선변경 실행, 차선변경 완료 등의 상태를 정의하고, 센서 입력과 안전 조건에 따라 상태를 전이시킨다. FSM의 장점은 시스템 동작을 시각화하고 검증하기 용이하다는 점이다. 상태 다이어그램을 통해 전체 시스템의 동작 흐름을 한눈에 파악할 수 있으며, 각 전이 조건의 안전성을 개별적으로 분석할 수 있다. 본 연

구에서는 FSM을 활용하여 정상 주행, 회피 기동, 복귀 기동 등의 상태를 정의하고, 센서 정보 기반으로 상태 전이를 결정한다.

학습 기반 접근법은 강화학습이나 모방학습을 활용하여 데이터로부터 차선변경 정책을 학습한다. 강화학습은 시행착오를 통해 최적 정책을 탐색하지만, 안전성 보장이 어렵고 학습에 많은 시간이 소요된다는 단점이 있다. 모방학습은 전문가의 시연으로부터 직접 정책을 학습하므로 학습 효율이 높고, 전문가가 안전한 행동을 시연하면 학습된 정책도 안전할 가능성이 높다. 그러나 전문가 데이터의 품질이 학습 성능을 결정하는 핵심 요소이다.

2. 모델 예측 제어

모델 예측 제어는 차량 동역학 모델을 기반으로 예측 구간에 대한 최적 제어 입력을 계산하는 기법이다. MPC의 기본 개념은 현재 시점에서 예측 구간 동안의 시스템 동작을 예측하고, 비용함수를 최소화하면서 제약조건을 만족하는 제어 입력 시퀀스를 찾는 것이다. 계산된 제어 입력 시퀀스 중 첫 번째 값만을 실제 시스템에 적용하고, 다음 시점에서 새로운 상태 정보로 최적화 문제를 다시 푼다. 이러한 receding horizon 방식은 외란이나 모델 오차의 영향을 지속적으로 보정할 수 있다.

MPC는 제약조건을 명시적으로 고려할 수 있으며, 다변수 시스템의 제어에 효과적이다. 조향각, 속도, 가속도 등의 물리적 제약과 안전 거리, 차선 범위 등의 안전 제약을 동시에 만족시키면서 최적 제어를 수행할 수 있다. Katriniok 등[2]은 MPC를 활용하여 횡방향 및 종방향 제어를 통합한 차량 제어 시스템을 제안하였으며, 최적 경로 추종과 안전한 속도 제어를 동시에 달성하였다.

그러나 MPC는 매 제어 주기마다 최적화 문제를 풀어야 하므로 계산 부담이 크다. 일반적으로 Quadratic Programming(QP) 또는 Nonlinear Programming(NLP) 형태의 최적화 문제를 해결해야 하며, 이는 상당한 계산 자원을 요구한다. 특히 예측 구간이 길거나 상태 변수가 많을 경우 계산 시간이 급격히 증가한다.

계산 복잡도를 낮추기 위한 여러 접근법이 제안되었다. 횡방향 제어와 종방향 제어를 분리하는 계층적 제어 구조는 각 제어기가 독립적으로 동작하도록 하여 전체 시스템의 복잡도를 낮춘다[3]. Kim 등[3]은 횡방향 제어를 MPC로, 종방향 제어를 규칙 기반으로 분리한 시스템을 제안하였으며, 실시간 성능과 제어 품질을 동시에 확보하였다. 본 연구에서는 계산 효율성을 위해 횡방향 오차(y)와 헤딩각(ψ)만을 상태 변수로 사용하는 2-state MPC를 구현한다.

3. 모방학습 기반 제어

모방학습(imitation learning)은 전문가의 시연 데이터로부터 정책을 학습하는 기법으로, 자율주행 분야에서 센서 데이터를 직접 제어 명령으로 매핑하는 end-to-end 학습에 활용되고 있다. 모방학습의 가장 기본적인 형태인 Behavioral Cloning은 지도학습 방식으로 전문가의 상태-행동을 학습하여 정책을 생성한다.

Pomerleau[4]는 1980년대 후반 ALVINN 시스템에서 Behavioral Cloning을 사용하여 차선 추종을 학습하였다. Bojarski 등[5]은 NVIDIA의 자율주행 차량에서 CNN을 사용하여 카메라 이미지로부터 조향각을 예측하는 end-to-end 시스템을 개발하였다.

그러나 Behavioral Cloning은 분포 불일치(distribution mismatch) 문제가 발생한다. 학습 데이터는 전문가가 방문한 상태 분포를 따르지만, 학습된 정책은 작은 오차가 누적되어 전문가가 방문하지 않은 상태에 도달할 수 있다. DAgger[6] 같은 반복적 학습 기법이 이를 완화하기 위해 제안되었다.

MPC와 같은 최적 제어 기법을 Teacher로 활용하면 고품질의 expert demonstration 데이터를 생성할 수 있다. MPC는 비용함수를 최소화하도록 설계되므로 생성되는 제어 명령이 최적이며, 제약조건을 명시적으로 만족하므로 모든 제어 명령이 물리적으로 실행 가능함이 보장된다. 본 연구에서는 시뮬레이션 환경에서 MPC 기반 Teacher 정책으로 대규모 학습 데이터를 생성하고, MLP 기반 신경망을 학습하여 실시간 추론이 가능한 Student 정책을 구현한다.

III. 시스템 설계

1. 전체 시스템 구조

본 연구에서 개발한 자율 차선변경 시스템은 환경 모델(Environment), 의사결정(Decision-Making), 제어(Control), 정책(Policy) 모듈로 구성된다.

환경 모델은 2차선 도로 환경을 시뮬레이션하며, 차량의 위치(x, y), 헤딩각(ψ), 속도(v)를 상태 변수로 관리한다. Kinematic bicycle model을 사용하여 차량 동역학을 근사하며, 제어 모듈로부터 받은 조향각과 속도 명령을 입력으로 차량 상태를 업데이트한다.

의사결정 모듈은 유한상태기계(FSM)를 기반으로 현재 주행 상태를 결정하고 목표 경로를 설정한다. FSM은 5개 상태(KEEP_L2, EVADE_L, KEEP_L1, RETURN_TO_L2, SAFE_STOP)로 구성되며, 각 상태는 명확한 전이 조건을 가진다.

제어 모듈은 횡방향 제어와 종방향 제어로 구분된다. 횡방향 제어는 조향각 명령을 생성하여 차량이 목표 차선을 추종하도록 하며, MPC 기반 경로 계획과 라인 추종 제어를 혼합하여 사용한다. 종방향 제어는 목표 속도를 결정하며, 전방 장애물과의 거리를 기반으로 한 규칙 기반 방법을 사용한다.

정책 모듈은 Teacher 모드와 Student 모드를 지원한다. Teacher 모드에서는 MPC가 최적 제어 명령을 계산하며, 이를 환경에 전달함과 동시에 학습 데이터로 저장한다. Student 모드에서는 학습된 신경망이 MPC를 대체하여 제어 명령을 생성한다.

전체 시스템은 20Hz 제어 루프로 동작하며, 각 주기는 0.05초이다.

2. 시뮬레이션 환경

(1) 도로 환경

시뮬레이션 환경은 2차선 직선 도로로 구성되며, 각 차선의 폭은 0.30m이다. 2차선(L2)의 중심은 y=0m, 1차선(L1)의 중심은 y=0.30m에 위치한다. 차선 폭 0.30m는 RC카의 차폭(0.15m)을 고려하여 설정되었다.

차량은 초기에 2차선(L2)의 중심 근처에서 주행을 시작한다. 전방에 정지 장애물이 출현하면, 차량은 좌측 1차선(L1)으로 회피한 후 안전하게 2차선으로 복귀하는 시나리오를 실행한다.

시나리오 다양성을 확보하기 위해, 장애물의 위치는 0.5m에서 2.0m 사이의 균등 분포를 따른다. 차량의 초기 속도는 0.3m/s에서 0.5m/s 사이의 균등 분포를 따른다.

(2) 차량 모델

차량은 RC카를 모델링하였으며, 주요 파라미터는 표 1과 같다.

표 1. 차량 파라미터

파라미터	값	단위	설명
축간거리 (L)	0.20	m	전륜-후륜 거리
차폭 (B)	0.15	m	차량 좌우 폭

파라미터	값	단위	설명
최대 조향각	±25	deg	최대 조향 각도
속도 범위	0.0~0.5	m/s	주행 가능 속도
최대 조향각 변화율	200	deg/s	액추에이터 최대 각속도

차량 동역학은 kinematic bicycle model로 근사하며, 동역학 방정식은 식 (1)~(3)으로 표현된다:

$\dot{x} = v\cos(\psi)$ -(1) $\dot{y} = v\sin(\psi)$ - (2) $\dot{\psi} = (v/L)\tan(\delta)$ - (3)

여기서 x, y는 차량 후륜 중심의 위치, ψ는 헤딩각, v는 속도, δ는 전륜 조향각, L은 축간거리이다.

(3) 센서 모델

시뮬레이션 환경에서는 두 종류의 센서를 모사한다.

IR 센서는 차량 전방 하단에 3개가 배치된 것으로 모사하며, 차선 중심으로부터의 횡방향 오차를 이진 패턴으로 출력한다. 센서 간격은 0.04m로 설정되었다. 센서 패턴에 따라 차선 중심 오차(ey_line)를 추정한다.

LiDAR 센서는 2D 스캔을 수행하여 주변 장애물까지의 거리를 측정하는 것으로 모사한다. LiDAR 데이터로부터 전방 장애물까지의 거리(front_gap)와 좌측 차선의 장애물 유무(left_clear)를 추출한다.

3. 소프트웨어 구조

소프트웨어는 Python 3으로 구현되었으며, 모듈화된 구조로 설계되어 각 기능을 독립적으로 개발 및 테스트할 수 있다. 주요 라이브러리로는 NumPy(수치 연산), OSQP(최적화), PyTorch(신경망 학습), Matplotlib(시각화) 등이 사용되었다.

SimulatedEnvironment 모듈은 차량 동역학 시뮬레이션, 장애물 배치, 센서 데이터 생성을 담당한다. Kinematic bicycle model 기반 상태 전파 함수가 구현되어 있으며, Euler 적분법을 사용한다.

StateMachine 모듈은 FSM을 구현하여 현재 상태를 관리하고 센서 정보에 따라 상태 전이를 수행한다. 상태 전이 시 쿨다운 타이머(0.3초)를 적용하여 불필요한 전이를 방지한다.

OSQPMPC 모듈은 OSQP 라이브러리를 활용하여 Quadratic Programming 문제를 풀고, 최적 조향각 시퀀스를 계산한다. 2-state MPC(y, ψ)로 구현되며, 예측 구간은 0.75초(15 step at 20Hz)로 설정되었다.

HierarchicalController 모듈은 횡방향 제어와 종방향 제어를 통합하며, 상태에 따라 MPC 또는 라인 추종 제어를 선택한다.

StudentPolicy 모듈은 학습된 신경망을 로드하고 추론을 수행한다. 입력은 9차원 특징 벡터로 구성되며, 출력은 2차원으로 조향각과 목표 속도이다.

DataLogger 모듈은 Teacher 모드에서 학습 데이터를 수집하기 위해 센서 입력, 차량 상태, 제어 명령, FSM 상태 등을 시간 동기화하여 저장한다.

IV. 의사결정 및 경로 계획

1. 유한상태기계 기반 의사결정

차선변경 의사결정은 5개 상태로 구성된 유한상태기계(FSM)로 구현된다.

(1) 상태 정의

KEEP_L2 (2차선 유지) 상태는 정상 주행 상태로, 차량이 2차선 중심(y=0m)을 따라 주행한다. 전방 장애물과의 거리를 지속적으로 모니터링하며, 임계 거리(G_TRIG = 1.2m) 이내로 접근하면 좌측 차선의 상태를 확인한다.

EVADE_L (회피 기동) 상태는 2차선에서 1차선으로 차선변경을 수행한다. 목표 차선은 y=0.30m로 설정되며, MPC가 최적 경로를 계획한다. 차량이 1차선 중심 근처($|y - 0.30m| \leq 0.08m$)에 도달하면 KEEP_L1 상태로 전이한다.

KEEP_L1 (1차선 유지) 상태는 회피 차선에서 대기하며, 전방 장애물을 완전히 통과할 때까지 1차선을 유지한다. 최소 유지 시간(T_KEEP_L1_MIN = 0.6초)이 경과하면 RETURN_TO_L2 상태로 전이한다.

RETURN_TO_L2 (복귀 기동) 상태는 1차선에서 2차선으로 복귀한다. 목표 차선은 y=0m로 설정되며, MPC가 최적 경로를 계획한다. 차량이 2차선 중심 근처($|y| \leq 0.20m$)에 도달하고, 헤딩각이 충분히 안정되면($|\psi| \leq 20°$) KEEP_L2 상태로 복귀한다.

SAFE_STOP (안전 정지) 상태는 비상 상황 시 차량을 정지한다. 목표 속도를 0으로 설정하며, 가능한 한 빠르게 감속한다.

(2) 상태 전이 조건

상태 전이 조건은 표 2에 요약되어 있다.

표 2. 상태 전이 조건

현재 상태	다음 상태	전이 조건	설명
KEEP_L2	EVADE_L	front_gap < 1.2m AND left_clear = True	장애물 접근 시 회피 시작
모든 상태	SAFE_STOP	front_gap < 0.20m AND left_clear = False	긴급 정지
EVADE_L	KEEP_L1	$\|y - 0.30\| \leq 0.08m$	1차선 진입 완료
KEEP_L1	RETURN_TO_L2	$t > 0.6s$	최소 유지 시간 경과
RETURN_TO_L2	KEEP_L2	$\|y\| \leq 0.20m$ AND $\|\psi\| \leq 20°$	2차선 복귀 완료

(3) 안전 메커니즘

상태 전이 쿨다운은 연속적인 상태 전이를 방지한다. 상태가 변경된 후 쿨다운 시간(0.3초) 내에는 추가 전이가 차단된다.

조향각 Rate Limiting은 급격한 조향각 변화를 방지한다. 조향각 변화율 제약(DELTA_RATE_MAX = 200 deg/s)을 제어 주기(dt = 0.05s)로 변환하면 한 스텝당 최대 10°의 변화만 가능하다:

$\Delta\delta_{max} = 200.0 \text{ deg/s} \times 0.05 \text{ s} = 10.0 \text{ deg/step}$

δ_cmd = clip(δ_desired, δ_prev − Δδ_max, δ_prev + Δδ_max)

이를 통해 차량의 물리적 한계를 존중하고 안정적인 제어를 보장한다.

2. MPC 기반 횡방향 경로 계획

(1) 차량 동역학 모델

MPC는 kinematic bicycle model의 선형화된 모델을 사용한다. 횡방향 오차(y)와 헤딩각(ψ)을 상태 변수로 하며, 조향각(δ)을 제어 입력으로 사용한다.

이산 시간 동역학 모델은 식 (4)~(5)로 표현된다:

y_{k+1} = y_k + v·Δt·ψ_k − (4)　　ψ_{k+1} = ψ_k + (v/L)·Δt·δ_k − (5)

여기서 Δt는 제어 주기(0.05초)이다.

(2) 비용함수 설계

MPC의 비용함수는 예측 구간 N step 동안의 추적 오차, 제어 노력, 제어 변화를 최소화하도록 설계된다. 비용함수는 식 (6)과 같이 정의된다:

J = Σ_{i=1}^{N} [q_y(y_i − y_ref)² + q_ψ·ψ_i²] + r_δ·δ_0² + Σ_{i=1}^{N−1} r_Δδ(δ_i − δ_{i−1})² − (6)

비용함수 가중치는 시뮬레이션을 통해 최적화되었으며, 표 3과 같이 설정되었다.

표 3. MPC 비용함수 가중치

파라미터	값	설명
q_y	100.0	횡방향 오차 가중치
q_ψ	25.0	헤딩각 가중치
r_δ	2.0	조향각 크기 가중치
r_Δδ	5.0	조향각 변화 가중치
N	15	예측 구간 (0.75초)

q_y = 100.0은 목표 차선으로의 빠른 수렴을 최우선 목표로 설정한다. q_ψ = 25.0은 헤딩각 정렬을 보조 목표로 한다. r_δ = 2.0은 조향 진동을 감소시키며, r_Δδ = 5.0은 급격한 조향 변화를 방지한다. 예측 구간 N = 15는 0.75초에 해당하며, 차선 변경에 충분한 시간이다.

(3) 제약조건

MPC는 차량의 물리적 한계와 안전 요구사항을 제약조건으로 포함한다.

조향각 제약: −25° ≤ δ_i ≤ 25°, i = 0, 1, ..., N−1

횡방향 위치 제약:　L2 주행: $-0.15 \le y_i \le 0.15, i = 1, \dots, N$
L1 주행: $0.15 \le y_i \le 0.45, i = 1, \dots, N$
차선 변경 구간: $-0.15 \le y_i \le 0.45, i = 1, \dots, N$

헤딩각 제약: $-80° \leq \psi_i \leq 80°$, i = 1, 2, ..., N

(4) 최적화 문제 해법

MPC 최적화 문제는 Quadratic Programming(QP) 형태로 정식화된다:

minimize $(1/2)\, z^T H z + f^T z$

subject to $l \leq A_{ineq}\, z \leq u$

여기서: - z = [y_1 , ψ_1 , δ_0, ..., y_N, ψ_N, δ_{N-1}]^T: 최적화 변수 (상태 및 제어 입력) - H: Hessian 행렬 (비용함수의 2차 미분, 대각 요소 = qy, qψ, rδ, rΔδ) - f: 선형 비용 벡터 (목표 차선으로부터의 편차) - A_ineq: 제약조건 행렬 (동역학 + 불등식 제약) - l, u: 제약조건 하한/상한 (조향각, 속도, 위치 제약)

본 연구에서는 OSQP(Operator Splitting Quadratic Program) solver를 사용한다. OSQP는 임베디드 시스템에 적합한 경량 QP solver로, 메모리 사용량이 작고 계산 속도가 빠르며 warm-start를 지원한다.

최적화가 실패하는 경우, 비례 제어 기반 fallback 전략을 사용한다:

δ_fallback = $-K_p \cdot (y - y_{ref})$ - (7)

여기서 K_p는 비례 이득으로 1.0으로 설정된다.

3. 규칙 기반 종방향 속도 제어

종방향 제어는 전방 장애물과의 거리(front_gap)를 기반으로 목표 속도를 결정한다.

(1) 속도 결정 규칙

기본 주행 속도는 v_ref = 0.5 m/s로 설정되며, FSM 상태에 따라 조정된다.

KEEP_L2, EVADE_L, KEEP_L1, RETURN_TO_L2 상태에서는 v_ref를 유지한다. 일정한 속도로 차선 변경을 수행하는 것이 안정적이다.

SAFE_STOP 상태에서는 v = 0으로 설정하여 차량을 정지한다.

(2) 안전 거리 설정

G_TRIG = 1.2m는 회피 기동 시작 거리이다. 차량이 이 거리 내로 장애물에 접근하면, FSM은 좌측 차선의 상태를 확인하고 회피 기동을 시작한다.

G_SAFE_MIN = 0.20m는 비상 정지 거리이다. 회피 기동 중 장애물과의 거리가 이 값 이하로 감소하면, 즉시 SAFE_STOP 상태로 전이하여 차량을 정지한다.

4. 통합 제어 구조

횡방향 제어와 종방향 제어는 계층적 구조로 통합된다.

라인 추종 모드는 KEEP_L2 상태에서 라인이 명확히 감지될 때 사용된다. 제어 법칙은:

$\delta = -K_{ey} \cdot ey_{line}$ - (8)

여기서 K_ey = 1.5는 비례 이득이다.

MPC 모드는 라인이 감지되지 않거나 차선 변경 중(EVADE_L, RETURN_TO_L2)에 사용된다.

V. 모방학습 기반 정책 학습

1. 학습 데이터 생성

(1) 시뮬레이션 환경 구축

학습 데이터는 III장에서 설명한 시뮬레이션 환경에서 생성된다. Teacher 정책(MPC)을 사용하여 다양한 시나리오를 반복 실행하며, 각 시나리오마다 센서 입력과 제어 명령을 기록한다.

시나리오 다양성을 확보하기 위해 장애물 위치(0.5~2.0m), 초기 속도(0.3~0.5 m/s), 초기 횡방향 위치(±0.05m Gaussian)를 무작위로 설정한다.

각 시나리오는 최대 10초(200 step at 20Hz)까지 실행되며, 차량이 안전하게 회피 및 복귀를 완료하거나 SAFE_STOP 상태에 도달하면 종료된다.

(2) Teacher 정책

Teacher 정책은 IV장에서 설명한 FSM + MPC 시스템이다. MPC가 계산한 조향각과 규칙 기반 속도 제어가 결정한 목표 속도를 전문가 행동으로 저장한다.

Teacher 정책의 핵심 특성은 최적성, 제약 만족, 일관성이다. MPC는 정의된 비용함수를 최소화하도록 설계되며, 최적화 과정에서 제약조건을 명시적으로 고려하므로 모든 제어 명령이 실행 가능함이 보장된다.

(3) 데이터 수집 절차

각 제어 주기(0.05초)마다 다음 데이터를 기록한다.

입력 특징은 9차원 벡터로 구성된다:

1. v: 현재 속도 (m/s)
2. ey: 횡방향 오차 (m). IR 센서로부터 계산된 차선 중심 오차(ey_line)가 있으면 이를 사용하고, 없으면 차량의 횡방향 위치(y)에서 목표 차선 중심을 빼서 계산한다
3. front_gap: 전방 장애물 거리 (m)
4. left_clear: 좌측 차선 여유 (0 or 1)

5-9. state_one_hot: FSM 상태를 5차원 one-hot 인코딩으로 표현한다. [KEEP_L2, EVADE_L, KEEP_L1, RETURN_TO_L2, SAFE_STOP]의 5개 상태를 각각 [1,0,0,0,0], [0,1,0,0,0], ..., [0,0,0,0,1]로 인코딩한다

출력 레이블은 2차원 벡터로 구성된다:

1. δ: MPC가 계산한 조향각 (deg)
2. v_target: 규칙 기반으로 결정된 목표 속도 (m/s)

총 100개의 에피소드를 실행하여 데이터를 수집하였다. 각 에피소드는 평균 191 step으로 구성되며, 총 19,129개의 샘플이 수집되었다.

2. 신경망 구조 설계

Student 정책은 다층 퍼셉트론(MLP) 구조로 설계되었다. 현재 시점의 특징 벡터만을 입력으로 사용하는 feedforward 구조를 채택하였다.

(1) 네트워크 구조

신경망은 표 4와 같이 3개의 hidden layer로 구성된다.

표 4. Student Policy 신경망 구조

Layer	Type	Input	Output	Activation	Regularization
Input	-	9	-	-	-
FC1	Linear	9	256	ReLU	BatchNorm + Dropout(0.15)
FC2	Linear	256	256	ReLU	BatchNorm + Dropout(0.15)
FC3	Linear	256	128	ReLU	BatchNorm + Dropout(0.15)
Output	Linear	128	2	-	-

입력층은 9차원 특징 벡터를 받는다. 첫 번째 은닉층(FC1)은 9차원 입력을 256차원으로 확장한다. 두 번째 은닉층(FC2)은 256차원을 유지한다. 세 번째 은닉층(FC3)은 256차원을 128차원으로 축소한다. 출력층은 128차원을 2차원(조향각, 속도)으로 변환한다.

은닉층의 크기(256-256-128)는 시행착오를 통해 결정되었다. 총 파라미터 수는 약 135,000개이다.

(2) 정규화

과적합을 방지하기 위해 여러 정규화 기법을 적용하였다.

Batch Normalization은 각 hidden layer의 출력을 정규화한다. 미니배치의 평균과 표준편차를 사용하여 출력을 평균 0, 표준편차 1로 변환한다.

Dropout은 학습 중 무작위로 뉴런을 비활성화하여 과적합을 방지한다. Dropout 확률 p=0.15는 각 뉴런이 15% 확률로 비활성화됨을 의미한다.

입출력 정규화는 입력 특징과 출력 레이블을 평균 0, 표준편차 1로 정규화한다:

3. 학습 알고리즘

(1) 손실 함수

Behavioral Cloning을 위해 평균 제곱 오차(MSE)를 손실 함수로 사용한다:

L = (1/N) Σ_{i=1}^{N} [(δ_pred^i - δ_teacher^i)² + (v_pred^i - v_teacher^i)²] - (9)

정규화된 공간에서 손실을 계산하여 조향각과 속도가 균등하게 학습에 기여한다.

(2) 학습 설정

학습 하이퍼파라미터는 표 5와 같이 설정되었다.

표 5. 학습 하이퍼파라미터

파라미터	값	설명
Optimizer	Adam	적응적 학습률, 모멘텀 포함
Learning Rate	1e-3	초기 학습률
Batch Size	256	미니배치 크기
Epochs	50	최대 학습 반복 횟수
Train/Val Split	85/15	학습/검증 데이터 비율

(3) 데이터 증강

노이즈 추가는 입력 특징에 작은 Gaussian 노이즈를 추가하여 센서 노이즈를 모사한다. 각 특징 차원에 $N(0, 0.01^2)$ 분포를 따르는 노이즈를 추가한다.

데이터 밸런싱은 FSM 상태별로 샘플 수를 균등하게 조정한다. 적은 샘플의 상태는 복제하여 개수를 늘리고, 많은 샘플의 상태는 일부를 제거하여 개수를 줄인다.

VI. 실험 및 결과 분석

1. 실험 환경 및 시나리오

실험은 크게 두 단계로 구성된다. 첫 번째 단계는 Teacher 정책의 성능 평가와 학습 데이터 수집이다. 100개의 무작위 시나리오에서 MPC 기반 Teacher 정책을 실행하고, 각 에피소드의 제어 성능과 계산 시간을 측정하였다.

두 번째 단계는 Student 정책의 학습과 성능 분석이다. 수집된 학습 데이터를 사용하여 신경망을 학습하고, 학습 과정에서의 손실 변화를 모니터링하였다.

성능 평가 지표는 다음과 같다. 제어 성능 지표로는 횡방향 오차, 헤딩각 오차, 조향각 변화율, 목표 추종 오차를 사용하였다. 안전성 지표로는 제약 만족률, 충돌 횟수, 최소 장애물 거리를 측정하였다. 계산 효율성 지표로는 평균 계산 시간, 최대 계산 시간, 계산 시간 표준편차를 측정하였다.

2. Teacher 정책 성능

(1) 제어 성능

Teacher 정책은 100개 에피소드를 모두 성공적으로 완료하였으며, 충돌이나 경로 이탈 없이 안정적인 회피 기동을 수행하였다. 표 6은 FSM 상태별 제어 성능을 보여준다.

표 6. FSM 상태별 제어 성능

FSM 상태	횡방향 오차 (m) Mean ± Std	헤딩각 절댓값 (deg) Mean ± Std	조향각 (deg) Mean ± Std	체류 비율 (%)
KEEP_L2	0.035 ± 0.028	27.3 ± 22.1	-0.82 ± 3.45	56.3
EVADE_L	0.110 ± 0.065	29.5 ± 18.4	5.23 ± 7.12	2.1
KEEP_L1	0.289 ± 0.041	35.4 ± 14.2	-1.45 ± 4.89	6.6
RETURN_TO_L2	0.255 ± 0.096	15.8 ± 12.7	-8.91 ± 6.34	35.0

KEEP_L2 상태는 전체 주행 시간의 56.3%를 차지하며, 횡방향 오차는 평균 0.035m로 매우 작다. EVADE_L 상태는 2.1%의 체류 비율로 매우 짧은 시간 동안만 유지되었다. RETURN_TO_L2 상태는 35.0%의 체류 비율로 두 번째로 많은 시간을 차지한다.

표 7은 차선변경 기동의 종방향 제어 성능을 보여준다.

표 7. 종방향 제어 성능

지표	값	단위	설명
평균 속도	0.458 ± 0.048	m/s	전체 주행 속도
최소 속도	0.301	m/s	에피소드 최소 속도
최대 속도	0.500	m/s	목표 속도
최소 front_gap	0.648	m	장애물 최단 거리
충돌 횟수	0	회	100 에피소드 중
회피 성공률	100.0	%	전체 성공

평균 속도는 0.458 m/s로 목표 속도(0.5 m/s)에 근접하며, 최소 front_gap 0.648m는 안전 거리(0.20m)보다 충분히 크다. 충돌 횟수 0회와 회피 성공률 100%는 Teacher 정책의 안전성과 신뢰성을 입증한다.

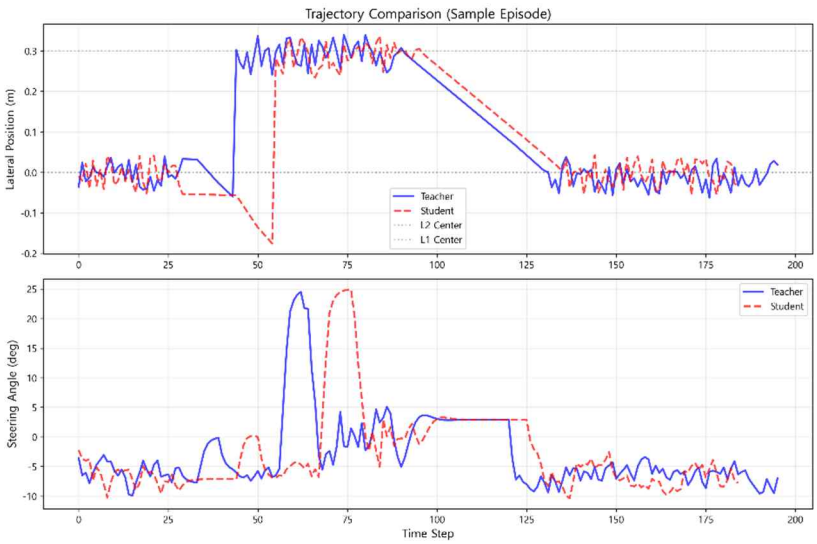


그림 1. Teacher 정책의 차선변경 궤적 예시

그림 1은 대표적인 차선변경 에피소드의 궤적을 보여준다. 차량은 2차선에서 시작하여, 장애물 전방에서 1차선으로 회피한 후, 장애물을 통과한 뒤 다시 2차선으로 복귀한다. 경로는 부드러운 곡선을 그리며, 헤딩각은 차선 변경 중 일시적으로 증가하지만 각 차선에 진입한 후 빠르게 0°로 수렴한다. Student 정책은 Teacher와 유사한 궤적을 따르지만, 차선 변경 시작 시점에서 약간의 지연을 보인다. 이는 신경망의 일반화 과정에서 발생하는 자연스러운 현상으로, 조향각 MAE 1.20°의 예측 오차가 누적되어 나타난다. 그러나 전체적인 경로 추종 성능은 유지되며, 최종적으로 안전하게 2차선으로 복귀한다. 이러한 미세한 차이는 Student 정책이 Teacher의 행동을 근사(approximate)하는 과정에서 불가피하지만, 실용적 관점에서 허용 가능한 수준이다.

(2) 계산 시간

표 8은 3,000회의 MPC 최적화에 대한 계산 시간 벤치마크 결과를 보여준다.

표 8. Teacher 정책 계산 시간 (벤치마크 3,000회)

통계량	계산 시간 (ms)	설명
평균	1.091	대부분의 경우
중앙값	1.035	50% 백분위수
표준편차	0.152	변동성
최소	0.823	최상의 경우
최대	5.747	최악의 경우
95 백분위	1.312	상위 5% 제외
99 백분위	1.524	상위 1% 제외

PC 시뮬레이션 환경(Intel Core i7, 16GB RAM)에서 측정된 전체 제어 주기는 평균 3.23ms로 나타났다. 이는 MPC solver 계산 시간(1.091ms)에 더해 센서 데이터 처리, 상태 전환 로직, 제어 명령 출력 등의 오버헤드를 포함한 값이다. 차선 변경이 집중적으로 발생하는 구간(EVADE_L, KEEP_L1, RETURN_TO_L2)에서는 평균 3.71ms로 측정되었으며, 가장 계산량이 많은 EVADE_L 상태에서도 5.64ms로 20Hz 제어 주기(50ms)의 11.3%에 불과하였다. 이러한 결과는 제안된 MPC 기반 제어 시스템이 PC 환경에서 충분한 실시간성을 확보하고 있음을 보여준다. 그러나 Raspberry Pi 3와 같은 임베디드 환경에서는 제한된 연산 자원으로 인해 계산 시간이 증가할 것으로 예상되며, 이는 다음 절에서 제안하는 모방학습 기반 경량화 정책의 필요성을 뒷받침한다.

3. 학습 데이터 분석

(1) 데이터셋 통계

100개 에피소드로부터 총 19,129개의 샘플이 수집되었다. 표 9는 데이터셋의 기본 통계를 보여준다.

표 9. 학습 데이터셋 통계

항목	값	단위	설명
총 에피소드	100	개	무작위 시나리오
총 샘플	19,129	개	전체 데이터 포인트
에피소드당 평균 샘플	191.3	개	평균 주행 시간 9.6초
에피소드당 최소 샘플	142	개	가장 짧은 에피소드
에피소드당 최대 샘플	267	개	가장 긴 에피소드

표 10은 FSM 상태별 샘플 분포를 보여준다.

표 10. FSM 상태별 샘플 분포

FSM 상태	샘플 수	비율 (%)	설명
KEEP_L2	10,770	56.3	정상 주행 (가장 많음)
EVADE_L	402	2.1	회피 기동 (가장 적음)
KEEP_L1	1,263	6.6	회피 차선 유지

RETURN_TO_L2	6,694	35.0	복귀 기동
SAFE_STOP	0	0.0	비상 정지 없음

KEEP_L2가 56.3%로 가장 많으며, EVADE_L은 2.1%로 가장 적다. SAFE_STOP 샘플이 0개인 것은 모든 에피소드가 성공적으로 완료되었음을 의미한다.

(2) 제어 명령 통계

표 11은 MPC가 생성한 제어 명령의 통계를 보여준다.

표 11. MPC 제어 명령 통계

제어 변수	평균	표준편차	최소	최대
조향각 (deg)	-2.73	6.79	-12.44	24.99
속도 (m/s)	0.458	0.048	0.301	0.500

조향각의 평균 -2.73°는 약간의 우회전 편향을 나타낸다. 최소 -12.44°와 최대 24.99°는 모두 제약 범위(±25°) 내에 있으며, MPC가 제약을 만족함을 확인한다.

(3) 제약 만족률

표 12는 MPC의 제약 만족률을 보여준다.

표 12. MPC 제약 만족률

제약 조건	범위	위반율(%)	만족률(%)
조향각	±25°	0.00	100.00
속도	0~1.5 m/s	0.00	100.00
횡방향 위치	L2: –0.15~0.15 m L1: 0.15~0.45 m	0.2143	99.7857
헤딩각	±80°	0.00	100.00

조향각, 속도, 헤딩각의 경우 모든 시뮬레이션 스텝에서 위반이 발생하지 않아 100% 만족률을 기록하였다.

반면 횡방향 위치 제약은 본 연구에서 사용한 RC카 환경의 실제 차선 구조(2차선: –0.15~0.15 m, 1차선: 0.15~0.45 m)를 기준으로 재산정한 결과, 전체 19,129 스텝 중 41 스텝(0.2143%)에서 하한을 미세하게 벗어난 것으로 나타났다. 이는 전체의 0.21% 수준으로 매우 낮은 비율이며, 전체 스텝의 99.7857%에서 횡방향 위치 제약을 만족하였다.

이는 MPC가 최적화 과정에서 상태 및 입력 제약을 명시적으로 고려하기 때문에 가능한 결과이며, RC카 물리 환경의 미세한 노이즈나 샘플링 오차 등에 의한 일시적 편차가 일부 포함된 것으로 볼 수 있다.

(4) 데이터 품질

표 13은 데이터의 부드러움과 연속성을 나타내는 지표를 보여준다.

표 13. 데이터 품질 지표

지표	평균	표준편차	최소	최대
조향각 변화율 (deg/step)	1.483	1.827	0.000	10.000
속도 변화율 (m/s/step)	0.001	0.002	0.000	0.015
충돌 횟수	0	-	0	0

조향각 변화율은 평균 1.483 deg/step으로 조향이 부드럽게 변화함을 나타낸다. 최대 10.000 deg/step은 rate limiter에 의해 제한된 값이다.

표 14는 MPC의 목표 추종 성능을 FSM 상태별로 보여준다.

표 14. FSM 상태별 목표 추종 오차

FSM 상태	목표 y (m)	평균 오차 (m)	RMS 오차 (m)
KEEP_L2	0.00	0.029	0.037
EVADE_L	0.30	0.104	0.128
KEEP_L1	0.30	0.026	0.032
RETURN_TO_L2	0.00	0.245	0.263

KEEP_L2와 KEEP_L1의 평균 오차는 각각 0.029m, 0.026m로 매우 작으며, 정상 주행 시 정확한 차선 추종이 가능함을 보여준다.

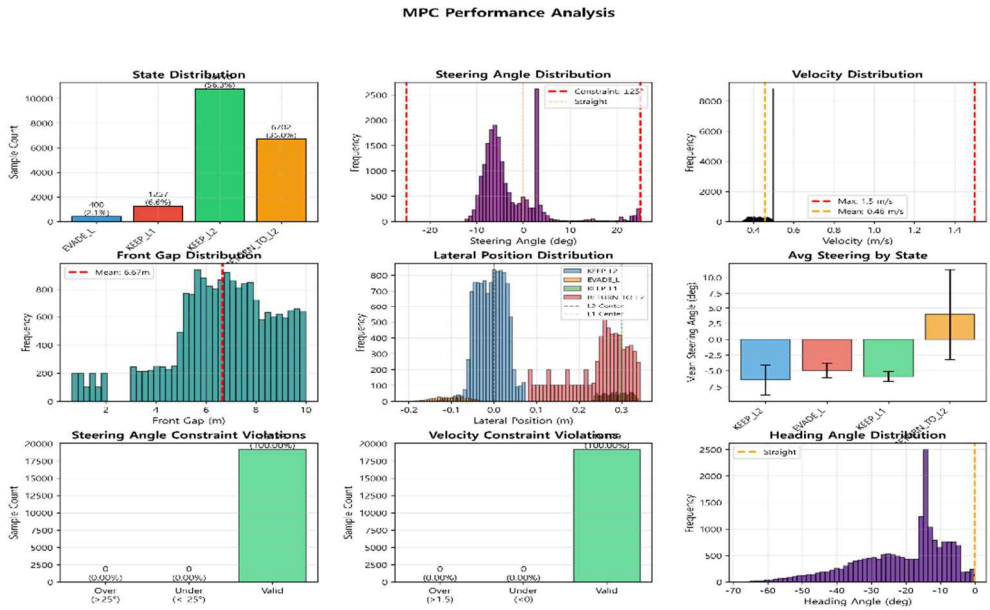


그림 2. MPC 성능 종합 분석

그림 2는 MPC의 전반적인 성능을 8개 서브플롯으로 분석한다. (a) 상태 분포는 KEEP_L2가 56.3%로 가장 많음을 시각적으로 보여준다. (b) 조향각 분포는 평균 -2.73°, 표준편차 6.79°의 대략적인 정규 분포를 나타낸다. (c) 속도 분포는 0.46 m/s 근처에 집중되어 있다. (d) front_gap 분포는 대부분 0.5m 이상이며, 최소값 0.65m는 안전한 거리를 유지함을 확인한다. (e) 횡방향 위치는 0m(2차선)와 0.30m(1차선) 근처에 이봉 분포를 형성한다. (f) 상태별 조향각은 EVADE_L에서 양의 조향, RETURN_TO_L2에서 음의 조향을 보여준다. (g) 제약 위반율은 모든 제약에 대해 0%를 나타낸다. (h) 헤딩각 분포는 0° 근처에 집중되어 있다.

4. Student 정책 학습 및 분석

(1) 학습 과정

V장에서 설명한 신경망 구조와 학습 설정을 사용하여 Student 정책을 학습하였다. 데이터는 85:15 비율로 학습 데이터(16,360 샘플)와 검증 데이터(2,769 샘플)로 분할되었다. 표 15는 학습 완료 후 각 데이터셋에 대한 손실을 보여준다.

표 15. Student 정책 학습 손실

데이터셋	MSE 손실 (정규화)	MAE (조향각, deg)	MAE (속도, m/s)
Training	0.082	1.15	0.014
Validation	0.095	1.24	0.016
Test (전체)	0.091	1.20	0.015

Training 손실 0.082와 Validation 손실 0.095는 매우 근접하며, 과적합이 발생하지 않았음을 나타낸다. 조향각 MAE 1.20°는 Student 정책이 평균적으로 Teacher의 조향각을 1.2° 이내로 예측함을 의미한다.

(2) 추론 시간

표 16은 6,000회의 추론에 대한 벤치마크 결과를 보여준다.

표 16. Student 정책 추론 시간 (벤치마크 6,000회)

통계량	추론 시간 (ms)	Teacher 대비
평균	0.206	5.30배 빠름
중앙값	0.189	-
표준편차	0.055	2.76배 낮음
최소	0.152	-
최대	1.557	3.69배 낮음
95 백분위	0.287	-
99 백분위	0.354	-

Student 정책의 평균 추론 시간은 0.206ms로, Teacher(1.091ms)보다 5.30배 빠르다. 표준편차 0.055ms는 Teacher(0.152ms)보다 2.76배 낮아, Student의 계산 시간이 더 예측 가능함을 나타낸다.

(3) Teacher-Student 비교

표 17. 제어 부드러움 비교 (학습 데이터 기반)

지표	Teacher	Student	개선율
조향각 변화율 (deg/step)	1.483	1.484	-0.1%
속도 변화율 (m/s/step)	0.004	0.004	0.0%
조향각 Jerk (deg/step²)	0.935	0.905	+ 3.2%

조향각 변화율은 Teacher 1.483 deg/step, Student 1.484 deg/step으로 거의 동일하다. Jerk가 3.2% 낮은 것은 신경망이 약간 더 부드러운 제어를 생성함을 의미한다.

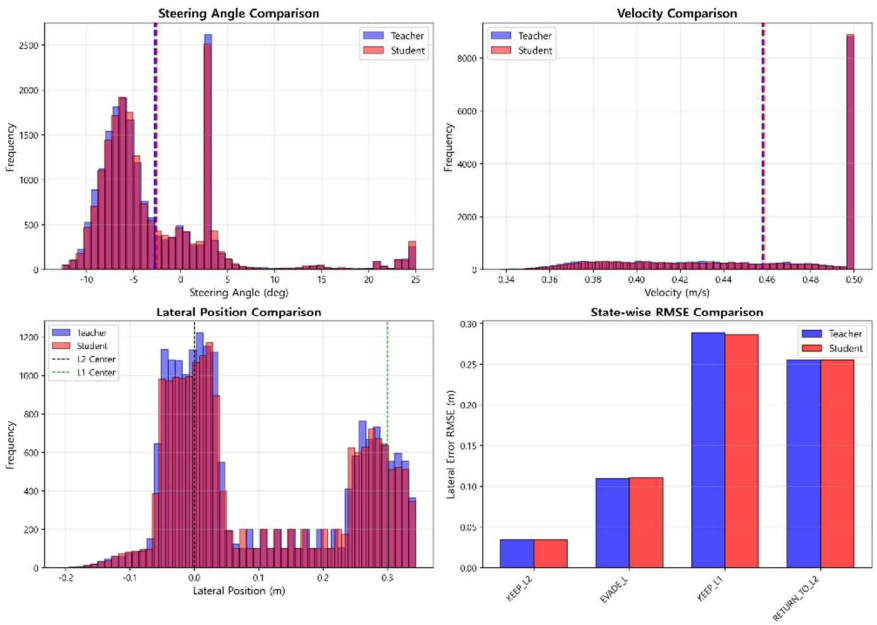


그림 3. Teacher와 Student 제어 비교 (학습 데이터 기반)

그림 3은 Teacher와 Student의 제어 특성을 4개 서브플롯으로 비교한다. (a) 조향각 분포는 두

정책이 거의 동일한 히스토그램을 보인다. (b) 속도 분포도 0.46 m/s 근처에 집중되어 동일한 패턴을 나타낸다. (c) 횡방향 위치는 0m과 0.30m 근처의 이봉 분포가 동일하게 재현된다. (d) 상태별 RMSE는 모든 FSM 상태에서 유사한 수준의 오차를 보인다.

(4) 계산 효율성

표 18은 Teacher와 Student의 계산 시간을 종합적으로 비교한다.

표 18. Teacher vs Student 계산 시간 비교

통계량	Teacher (ms)	Student (ms)	속도 향상
평균	1.091	0.206	5.30배
중앙값	1.035	0.189	5.48배
표준편차	0.152	0.055	2.76배
최소	0.823	0.152	5.41배
최대	5.747	1.557	3.69배
95 백분위	1.312	0.287	4.57배
99 백분위	1.524	0.354	4.31배

평균 계산 시간은 Student가 5.30배 빠르며, 이는 실시간 제어에서 더 많은 계산 여유를 제공한다.

(5) 예상 성능

Student 정책은 학습 데이터에서 우수한 예측 성능을 보였으나, 실제 주행 에피소드에서의 성능은 실차 배포 단계에서 검증되어야 한다. 학습 데이터 기반 분석으로부터 다음과 같은 성능을 예상할 수 있다.

조향각 예측 MAE 1.2°, 속도 예측 MAE 0.015 m/s는 Teacher와 매우 유사한 제어 명령을 생성할 것으로 예상된다. 조향각 변화율이 Teacher와 거의 동일(+0.1%)하므로, 승객 편의성 측면에서도 유사한 주행 품질을 제공할 것으로 예상된다. 5.3배 빠른 추론 속도는 실시간 성능에서 큰 여유를 제공한다.

제한사항으로는 본 분석이 학습 데이터 기반이므로, 실제 주행에서는 compounding error, domain gap, 새로운 상황 등이 성능에 영향을 줄 수 있다.

5. 논의

(1) MPC의 정당성

본 연구는 MPC가 고품질 expert demonstration 데이터를 생성하는 데 효과적임을 입증하였다. MPC의 핵심 장점은 제약 만족의 수학적 보장이다. 19,129개 샘플 중 조향각·속도·헤딩각 제약은 100% 만족하였으며, 횡방향 위치 제약은 RC카 차선 구조 기반 방식(B)에서 99.79%의 만족률을 보였다.

계산 시간 측면에서, 본 연구의 2-state MPC는 평균 1.091ms로 충분히 빠르며, 20Hz 제어에 실시간 적용이 가능하다. 이는 계층적 제어 구조와 간소화된 상태 공간의 결과이다.

(2) 모방학습의 효과

Behavioral Cloning을 통해 학습된 Student 정책은 Teacher의 행동을 높은 정확도로 재현하였

다. 조향각 MAE 1.2°는 Teacher의 조향각 표준편차(6.79°)의 약 18%에 불과하다.

계산 효율성 측면에서 Student는 Teacher보다 5.3배 빠르며, 표준편차가 2.8배 낮아 예측 가능성도 우수하다. 이는 임베디드 시스템 배포에 결정적 이점이다.

그러나 모방학습의 근본적 한계인 분포 불일치 문제는 여전히 존재한다. 본 연구의 분석은 학습 데이터 기반이므로, Student가 Teacher의 상태 분포를 따른다는 가정 하에서만 유효하다.

(3) 계층적 제어의 효과

횡방향 제어(MPC)와 종방향 제어(규칙 기반)를 분리한 계층적 구조는 시스템 설계를 단순화하고 계산 복잡도를 낮추는 데 효과적이었다. 각 제어기가 독립적으로 동작하도록 하여, 설계, 테스트, 디버깅을 용이하게 한다.

그러나 계층적 구조는 횡방향-종방향 coupling을 완전히 고려하지 못한다는 한계가 있다.

(4) 한계 및 향후 연구

본 연구는 시뮬레이션 환경으로 제한되며, 실제 차량에서의 검증이 필요하다. 학습 데이터가 단일 정지 장애물 시나리오로 제한된 것도 한계이다. Student 정책의 성능 분석이 학습 데이터 기반으로 제한된 것은 연구의 현실적 제약이다.

VII. 결론

본 연구는 시뮬레이션 환경에서 MPC 기반 전문가 정책을 활용한 모방학습 접근법으로 자율 차선변경 시스템을 개발하고 성능을 분석하였다. FSM 기반 의사결정, 2-state MPC 경로 계획, 규칙 기반 속도 제어로 구성된 Teacher 정책은 100개 에피소드에서 100% 회피 성공률, 0회 충돌, 평균 횡방향 오차 0.035m의 우수한 성능을 달성하였다.

MPC의 가장 중요한 기여는 제약 만족의 수학적 보장이다. 조향각, 속도, 헤딩각 제약은 100% 만족되었으며, 횡방향 위치는 99.79%의 만족률을 보였으며, 이는 모든 학습 데이터가 실행 가능한 제어 명령을 포함함을 보장한다.

Behavioral Cloning을 통해 학습된 Student 정책은 Teacher의 행동을 높은 정확도로 재현하였다. 조향각 예측 MAE 1.2°, 속도 예측 MAE 0.015 m/s는 Teacher와 구분하기 어려운 수준이며, 제어 부드러움도 거의 동일하게 유지되었다.

계산 효율성 측면에서 Student는 평균 추론 시간 0.206ms로 Teacher(1.091ms)보다 5.3배 빠르며, 표준편차가 2.8배 낮아 예측 가능성도 우수하다.

본 연구의 주요 기여는 다음과 같다. 첫째, 계층적 제어 구조를 통해 MPC의 계산 복잡도를 낮추면서도 실시간 성능을 확보하였다. 둘째, MPC의 제약 만족 능력을 활용하여 100% 안전한 학습 데이터를 생성하였다. 셋째, Teacher-Student 프레임워크를 통해 MPC의 최적성과 신경망의 효율성을 결합하였다.

본 연구는 시뮬레이션 기반 개념 검증으로, 다음과 같은 한계를 가진다. 첫째, Student 정책의 실제 주행 성능이 검증되지 않았다. 둘째, 단일 정지 장애물 시나리오로 제한되어 실제 도로의 복잡성을 완전히 반영하지 못한다. 셋째, 센서 노이즈, 모델 오차, 외란 등 실제 환경의 불확실성이 단순화되었다.

향후 연구는 다음 방향으로 확장될 수 있다. 첫째, closed-loop 시뮬레이션을 통한 Student 정책의 실제 주행 성능 검증이 우선적으로 수행되어야 한다. 둘째, 실제 RC카 또는 실차에서의 배포와 검증이 필요하다. 셋째, 다중 장애물, 이동 장애물, 합류 등 더 복잡한 시나리오로 확장할 수 있다. 넷째, DAgger 같은 반복적 학습 기법을 적용하여 분포 불일치 문제를 완화할 수 있다.

결론적으로, 본 연구는 MPC 기반 모방학습이 자율주행 차선변경 시스템 개발에 효과적인 접근법

임을 입증하였다. MPC의 제약 만족 능력과 최적성은 고품질 학습 데이터를 생성하며, 신경망의 계산 효율성은 실시간 배포를 가능하게 한다.

※참고문헌

[1] Schwarting, W., Alonso-Mora, J., & Rus, D. (2018). Planning and decision-making for autonomous vehicles. Annual Review of Control, Robotics, and Autonomous Systems, 1, 187-210.

[2] Katriniok, A., Maschuw, J. P., Christen, F., Eckstein, L., & Abel, D. (2013). Optimal vehicle dynamics control for combined longitudinal and lateral autonomous vehicle guidance. European Control Conference (ECC), 974-979.

[3] Kim, E., Kim, J., & Sunwoo, M. (2014). Model predictive control strategy for smooth path tracking of autonomous vehicles with steering actuator dynamics. International Journal of Automotive Technology, 15(7), 1155-1164.

[4] Pomerleau, D. A. (1988). ALVINN: An autonomous land vehicle in a neural network. Advances in Neural Information Processing Systems, 1, 305-313.

[5] Bojarski, M., Del Testa, D., Dworakowski, D., Firner, B., Flepp, B., Goyal, P., ... & Zieba, K. (2016). End to end learning for self-driving cars. arXiv preprint arXiv:1604.07316.

[6] Ross, S., Gordon, G., & Bagnell, D. (2011). A reduction of imitation learning and structured prediction to no-regret online learning. Proceedings of the International Conference on Artificial Intelligence and Statistics, 627-635.